Fine-Tuning du Modèle Depth Anything avec LoRA

Introduction

L'objectif de ce devoir est d'apprendre la technique du fine-tuning utilisant LoRA sur le modèle Depth Anything. Pour répondre à cet objectif, il faut comprendre 3 choses : ce qu'est le fine-tuning, le modèle Depth Anything et LoRA.

Le fine-tuning consiste à spécialiser un modèle sur une tâche précise. Plus précisément, les paramètres d'un modèle initial (réalisant une tâche d'ordre généraliste) seront mis à jour afin de réaliser des tâches spécifiques ou d'en ajuster son comportement. Par exemple, le fine-tuning est utilisé dans les grands modèles de langages pour pouvoir converser sur des sujets spécialisés comme le droit, la médecine etc.

Ce principe de fine-tuning sera appliqué au modèle Depth Anything. C'est un modèle avancé pour déterminer la distance relative des objets à partir d'une seule image. Développée par une équipe de chercheurs, cette approche vise à fournir des estimations de profondeur robustes pour n'importe quelle image, quelles que soient les conditions.

LoRA (Low Rank Adaptation) est une technique utilisée principalement pour adapter ou affiner des modèles d'apprentissage automatique pré-entraînés. Le principe global est de sélectionner des paramètres qui vont être gelés (« pretrained Weights » W) et des variables qui vont être réentraînées et compressées à un rang r. Cette méthode réduit considérablement les besoins en ressources computationnelles et en mémoire lors du fine tuning d'un modèle, ce qui permet de gagner beaucoup de temps. Il est particulièrement populaire dans le domaine des modèles de langage et des réseaux neuronaux profonds.

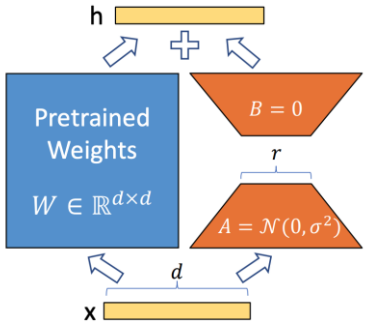

Figure 1 - Illustration de LoRA

Au début du projet, nous avons préparé l'environnement afin de pouvoir travailler en collaboration, nous avons donc créer un fichier requirements.txt avec l'ensemble des bibliothèques nécessaires. Sur le GitHub du projet https://github.com/Arthurmgnr/LoRA-Fine-Tuning, nous avons également noté toute la procédure pour créer l'environnement python pour faire fonctionner le projet dans un markdown README.

Chargement des données

Nous avons donc commencé par créer une classe DepthDataset qui va permettre de parcourir toutes les images ainsi que les nuages de points qui constituent notre dataset. Pour cela, on

stocke les chemins d'accès aux différents fichiers pour éviter de stocker en mémoire les images directement et alourdir la mémoire. Puis, lorsque l'on veut accéder à une image, le dataset renvoie l'image ainsi que le nuage de points associés. Les données ont été séparées en deux : un ensemble d'entrainement (80%) et un ensemble de validation (20%).
À ce moment-là, nous nous sommes rendu compte de plusieurs problèmes qui ont nécessité quelques modifications sur la classe initiale. Ces problèmes sont détaillés ci-dessous :

1. Nous nous sommes rendu compte que le modèle demandait en input des images qui sont des multiples de 14. Cela implique que les images doivent être redimensionnées.
2. Aussi, nous avons vu que les images n'étaient pas dans le bon code couleur, ils sont initialement en BGR. Nous les avons donc converties en RGB.
3. Après analyse de la structure des données depth, il est apparu qu'il y avait trois dimensions de profondeur : par rapport à l'axe X, l'axe Y et l'axe Z. Cette structure à l'avantage de pouvoir afficher un nuage de point en 3D. Cependant, depthanything, dans son output, retourne une profondeur donnée relativement par rapport à la prise de vue. Cela correspond mathématiquement à l'axe Z. Nous avons donc choisi de ne garder dans les données depth, que cette profondeur par rapport à l'axe Z.
4. Le dernier problème rencontré est la présence de données manquantes (NaN) dans les données de profondeur. Après vérification, notre conclusion est que ces données manquantes correspondent aux parties d'ombres sur les bordures de la plupart des images. Plusieurs solutions ont été envisagées : remplacer des données par une valeur fixe ou chercher à interpoler ces valeurs par leurs plus proches voisins. Finalement, nous avons choisi de faire la méthode par interpolation. Ce choix s'explique parce que certains NaN se situent au milieu de certains pneus, en conséquence replacer par la valeur la plus lointaine rendrait les données moins fiables pour un bon apprentissage.

Figure 2 - Exemple de photo du dataset avec de l'ombre

Implémentation de LoRA

Ensuite, nous avons créé une classe LoRALayer. Cette classe applique la formule données dans l'article qui est le produit de la couche d'input par les matrices A et B.
Une fois la couche LoRA construite, il faut pouvoir l'appliquer à toutes les couches QKV du modèle DepthAnything V2. A ce stade, nous nous sommes demandé sur quelles couches il fallait appliquer LoRA. Nous avons pensé qu'il serait intéressant de l'appliquer sur des couches convolutionnelles pour se spécialiser sur des images de pneus. Cependant, par simplicité, nous avons choisi de ne l'appliquer que sur les couches QKV.

Lorsque l'on applique LoRA uniquement sur les couches QKV : 48 paramètres sur les 263 du modèle sont entrainable.
Quand toutes les couches concernées ont été remplacées, il faut geler les paramètres des couches sur lesquelles nous n'avons pas appliqué les couches LoRA. L'objectif est de ne rendre entraînable que les paramètres des couches sur lesquelles il y a du LoRA, les autres seront les mêmes que le modèle DepthAnything d'origine.

Fine – Tuning

Maintenant que les données ont été chargées et que LoRA a été implémenté, il faut entrainer DepthAnything afin de le fine-tuner. À ce moment-là, plusieurs choix doivent être faits :

- L'optimiseur choisi est Adam
- Pour la fonction de perte, plusieurs choix étaient possibles : moyenne des erreurs quadratiques, moyenne des erreurs absolues, perte Invariante à l'Échelle Logarithmique et perte Invariante aux Changements d'Échelle et de Translation. Ici, dans ce cas, il n'y a pas vraiment de fonction coût qui soit meilleure que les autres, étant donné la complexité de la tâche à réaliser. D'autant plus que le modèle DepthAnything utilise une fonction coût propre à lui seul. Dans la suite du
- Le nombre d'epoch et de batch
- Pour des raisons de performances, on utilise moins d'images d'entrainement, nous limiterons le nombre d'images en entrainement.

Évaluation des performances

A présent, il nous faut évaluer le modèle fine-tuné sur l'ensemble de données de validation, ce qui nous permet d'évaluer les performances de l'adaptation. Pour ce faire, nous avons affiché plusieurs images. De gauche à droite, on affiche : l'image réelle (données), la profondeur suivant l'axe de la caméra (données), l'image des profondeurs prédites par le fine-tuning du modèle avec LoRA et l'image prédite avec le modèle DepthAnythingV2 original.

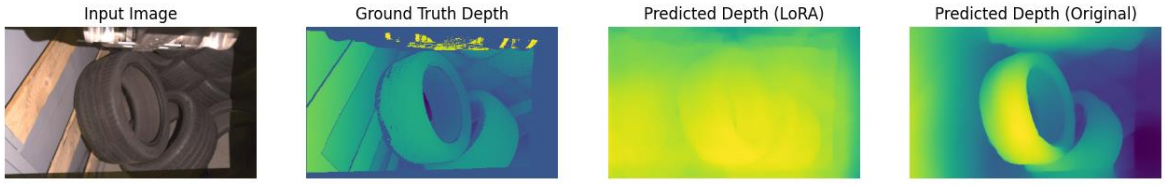

Figure 3 - Exemple d'image d'évaluation du fine-tuning de DepthAnythingV2 avec LoRA après le 2ème epoch

En plus du diagnostic visuel, on va regarder l'évolution de la fonction de perte. Nous allons comparer 3 cas différents avec à chaque fois 25 epochs. On peut voir que le meilleur résultat semble être le 1er, qui a été fait en mettant LORA uniquement sur des couches QKV et avec un ratio d'image de 10 (le ratio définit la résolution des images, plus le ratio est grand plus les images ont des détails). Ensuite, lorsque l'on applique LORA sur les couches QKV et sur les couches linéaires (2e et 3e cas), la fonction de perte converge beaucoup moins vite que dans le cas précédent. Enfin, entre les 2e cas et le 3e cas, on a simplement augmenté le ratio pour avoir des images avec plus de détails. La différence entre ces 2 cas n'est pas visible, le comportement de la fonction de perte est le même.

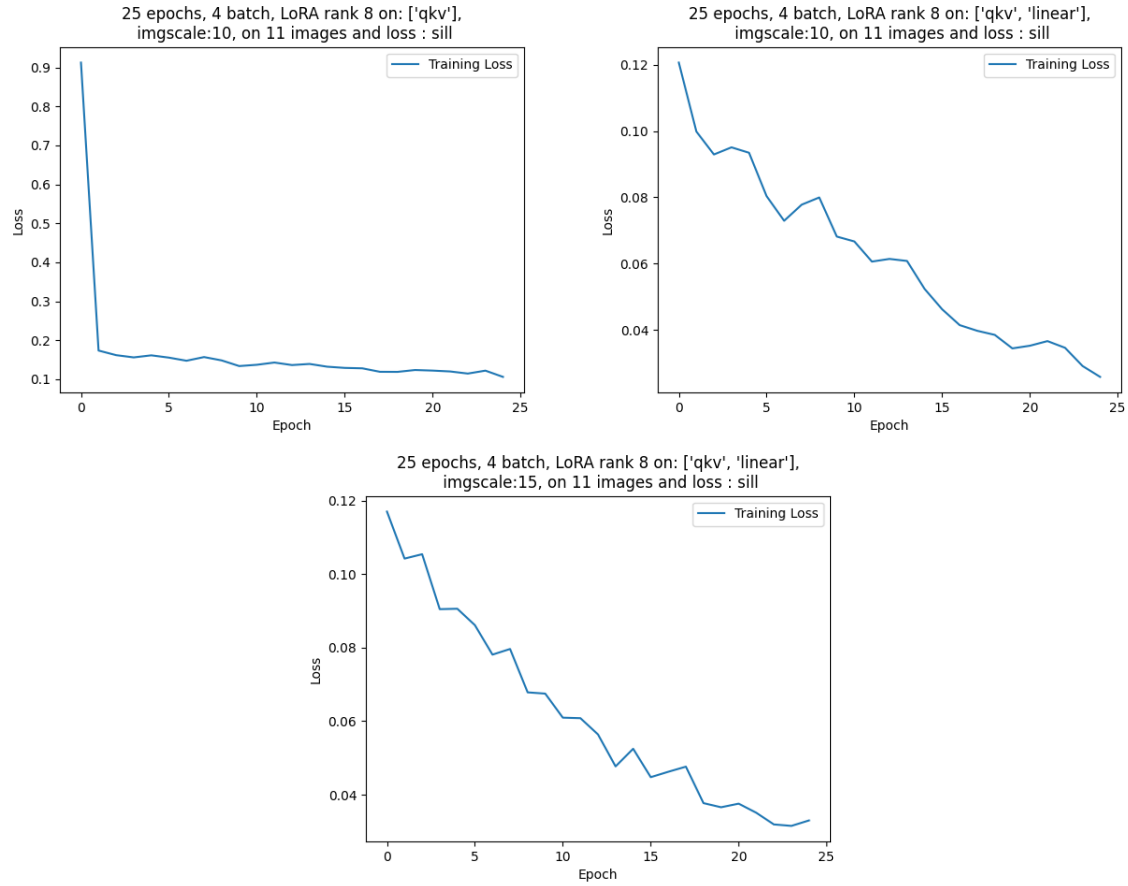

Figure 4 : Comparaison de l'évolution de la fonction de perte

Néanmoins, même si avec les 3 graphiques précédent, on voit qu'une certaine configuration semblerait fonctionner mieux que les autres, lorsque l'on regarde l'output de notre modèle par rapport au vrai nuage de points, les résultats ne sont très bons. L'ordre des configurations des images est le même que pour les graphiques.

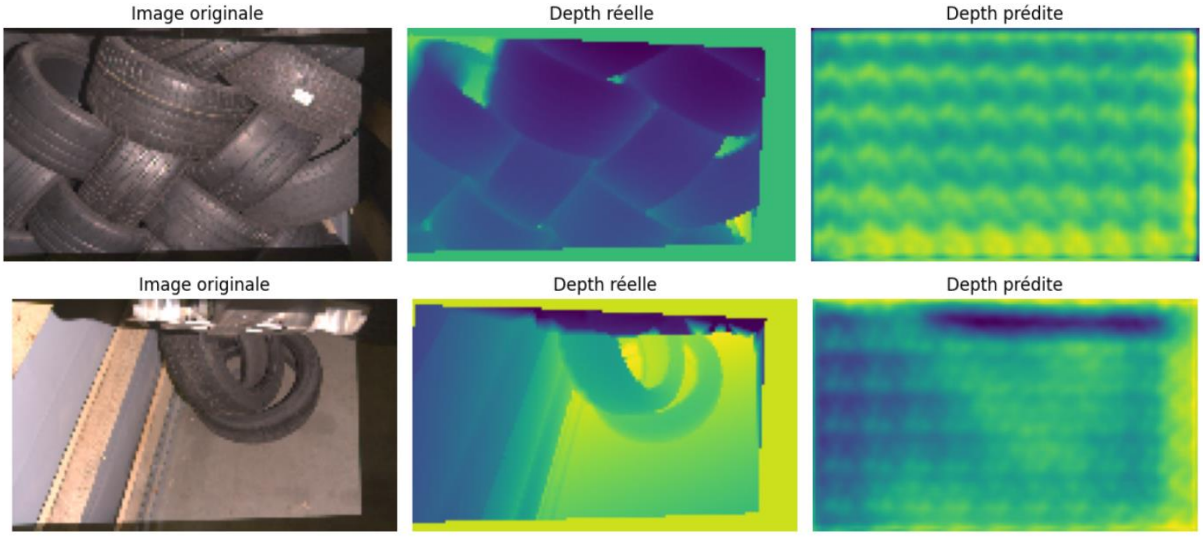

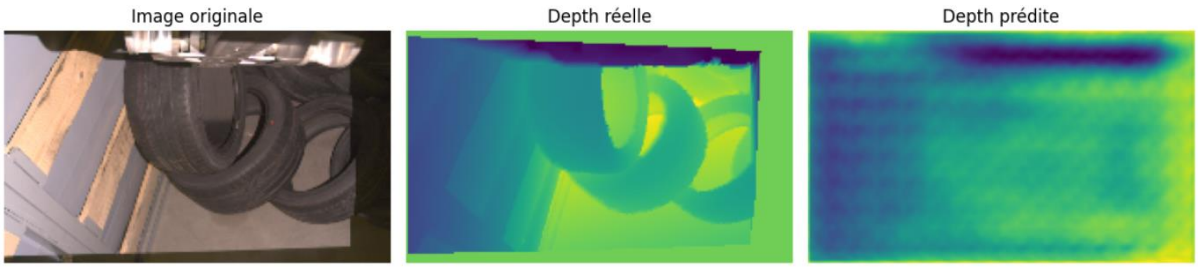

Enfin, pour continuer d'évaluer le diagnostic du modèle, nous avons mesuré le temps que met le programme à s'entraîner dans des conditions particulières résumées dans ce tableau[1] :

Nb Epochs	Nb Batch	Taille des images	Nb image entrainement	Couches LoRA	Temps (s)
25	4	84, 140	11	QKV + Linear	124
25	4	84,140	29	QKV	646
25	8	84,140	11	QKV	228
25	8	84,140	11	QKV + Linear	316
25	4	98,168	11	QKV	738

On se rend compte qu'un élément qui augmente énormément le temps sont les tailles d'images et le nombre d'images d'entrainement.

Conclusion

Pour conclure, nous avons dans l'ensemble bien réussi à appliquer la méthode du Fine-Tuning avec le modèle DepthAnythingV2. En effet, nous avons correctement : importé les données, appliquer LoRA sur des couches au choix et créer un algorithme d'entrainement. Enfin nous avons évaluer notre modèle sur les données de validation. Néanmoins, notre modèle ne fonctionne pas pour l'instant. Plusieurs pistes peuvent être envisagées pour améliorer notre modèle :

- Augmenter le nombre d'epochs pour que notre modèle s'entraîne davantage
- Augmenter la taille des images pour que notre modèle puisse mieux détecter les détails dans les images
- Augmenter le nombre d'images dans notre dataset, pour cela, on pourrait utiliser la méthode de « Data Augmentation » en effectuant des rotations d'images par exemple
- Appliquer LORA sur un plus grand nombre de couches dans le modèle DepthAnything (comme les couches convolutionnelles)

Cependant, il faut bien prendre conscience que ces différentes pistes augmentent la durée de l'exécution du code, et donc il s'agirait de faire un compromis entre amélioration des performances du modèle et la durée d'entraînement de notre modèle.

[1] Specs : 16CPU de 2GHz à 3.5GHz à 8 cœurs